

机器读心术之神经网络与深度学习 第4周

【声明】 本视频和幻灯片为炼数成金网络课程的教学资料，所有资料只能在课程内使用，不得在课程以外范围散播，违者将可能被追究法律和经济责任。

课程详情访问炼数成金培训网站

<http://edu.dataguru.cn>

关注炼数成金企业微信



- 提供全面的数据价值资讯，涵盖商业智能与数据分析、大数据、企业信息化、数字化技术等，各种高性价比课程信息，赶紧掏出您的手机关注吧！



John Joseph Hopfield

- John Hopfield received his BA from Swarthmore College, and a Ph.D in physics from Cornell University in 1958. He spent two years in the theory group at Bell Laboratories, and subsequently was a faculty member at University of California, Berkeley (physics), Princeton University (physics), California Institute of Technology (Chemistry and Biology) and now again at Princeton, where he is the Howard A. Prior Professor of Molecular Biology. For 35 years, he also continued a strong connection with Bell Laboratories.
- He was awarded the Dirac Medal of the ICTP in 2002 for his interdisciplinary contributions to understanding biology as a physical process, including the proofreading process in biomolecular synthesis and a description of collective dynamics and computing with attractors in neural networks, and the Oliver Buckley Prize of the American Physical Society for work on the interactions between light and solids. He is a member of the National Academy of Sciences, the American Philosophical Society, and the American Academy of Arts and Sciences. He was the President of the American Physical Society in 2006.
- <http://alex-wbf.blog.sohu.com/131663695.html>



Scanned at the American
Institute of Physics

Proc. Natl. Acad. Sci. USA
Vol. 79, pp. 2554–2558, April 1982
Biophysics

Neural networks and physical systems with emergent collective computational abilities

(associative memory/parallel processing/categorization/content-addressable memory/fail-soft devices)

J. J. HOPFIELD

Division of Chemistry and Biology, California Institute of Technology, Pasadena, California 91125; and Bell Laboratories, Murray Hill, New Jersey 07974

Contributed by John J. Hopfield, January 15, 1982

ABSTRACT Computational properties of use to biological organisms or to the construction of computers can emerge as collective properties of systems having a large number of simple equivalent components (or neurons). The physical meaning of content-addressable memory is described by an appropriate phase space flow of the state of a system. A model of such a system is given, based on aspects of neurobiology but readily adapted to integrated circuits. The collective properties of this model produce a content-addressable memory which correctly yields an entire memory from any subpart of sufficient size. The algorithm for the time evolution of the state of the system is based on asynchronous parallel processing. Additional emergent collective properties include some capacity for generalization, familiarity recognition, categorization, error correction, and time sequence retention. The collective properties are only weakly sensitive to details of the modeling or the failure of individual devices.

calized content-addressable memory or categorizer using extensive asynchronous parallel processing.

The general content-addressable memory of a physical system

Suppose that an item stored in memory is “H. A. Kramers & G. H. Wannier *Phys. Rev.* **60**, 252 (1941).” A general content-addressable memory would be capable of retrieving this entire memory item on the basis of sufficient partial information. The input “& Wannier, (1941)” might suffice. An ideal memory could deal with errors and retrieve this reference even from the input “Vannier, (1941)”. In computers, only relatively simple forms of content-addressable memory have been made in hardware (10, 11). Sophisticated ideas like error correction in accessing information are usually introduced as software (10).

There are classes of physical systems whose spontaneous be-

- 人类的联想记忆能力
- Hopfield人工神经网络能模拟联想记忆功能，曾被誉为神经网络方法的以此革命和再生
- Hopfield人工神经网络按动力学方式运行

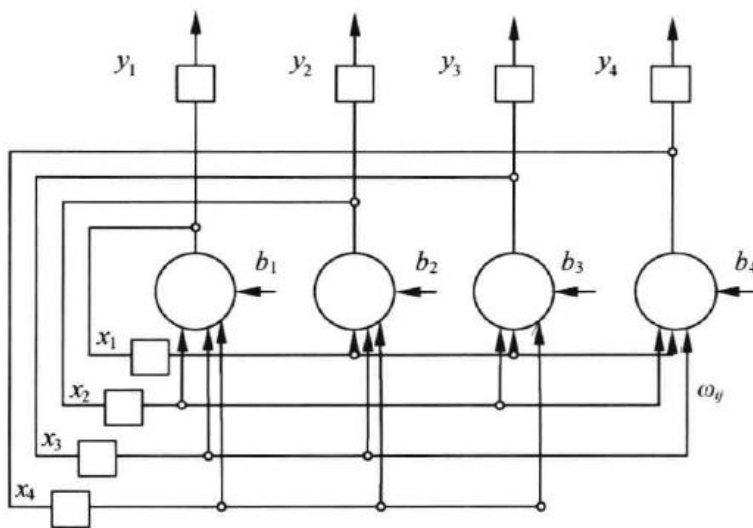


图 9-1 离散 Hopfield 网络







图 9-2 Hopfield 网络的网状结构





- DHNN，权值的对称性，无自反
- 离散型反馈神经网络
- 每个神经元功能相同，状态，阈值
- 输入初始值后即进入动力学演变





图 6.1 DHNN 网的拓扑结构

- 韩立群书第120页
- 转换函数为符号函数
- 异步工作方式
- 同步工作方式






图 6.2 反馈网络的三种相图

定义 5.1 若网络的状态 X 满足 $X = f(WX - T)$ ，则称 X 为网络的吸引子。

定理 5.1 对于 DHNN 网，若按异步方式调整网络状态，且连接权矩阵 W 为对称阵，则对于任意初态，网络都最终收敛到一个吸引子。

定理 5.2 对于 DHNN 网，若按同步方式调整状态，且连接权矩阵 W 为非负定对称阵，则对于任意初态，网络都最终收敛到一个吸引子。




图 9-3 稳定状态示意图




图 9-4 有限环网络




图 9-5 混沌

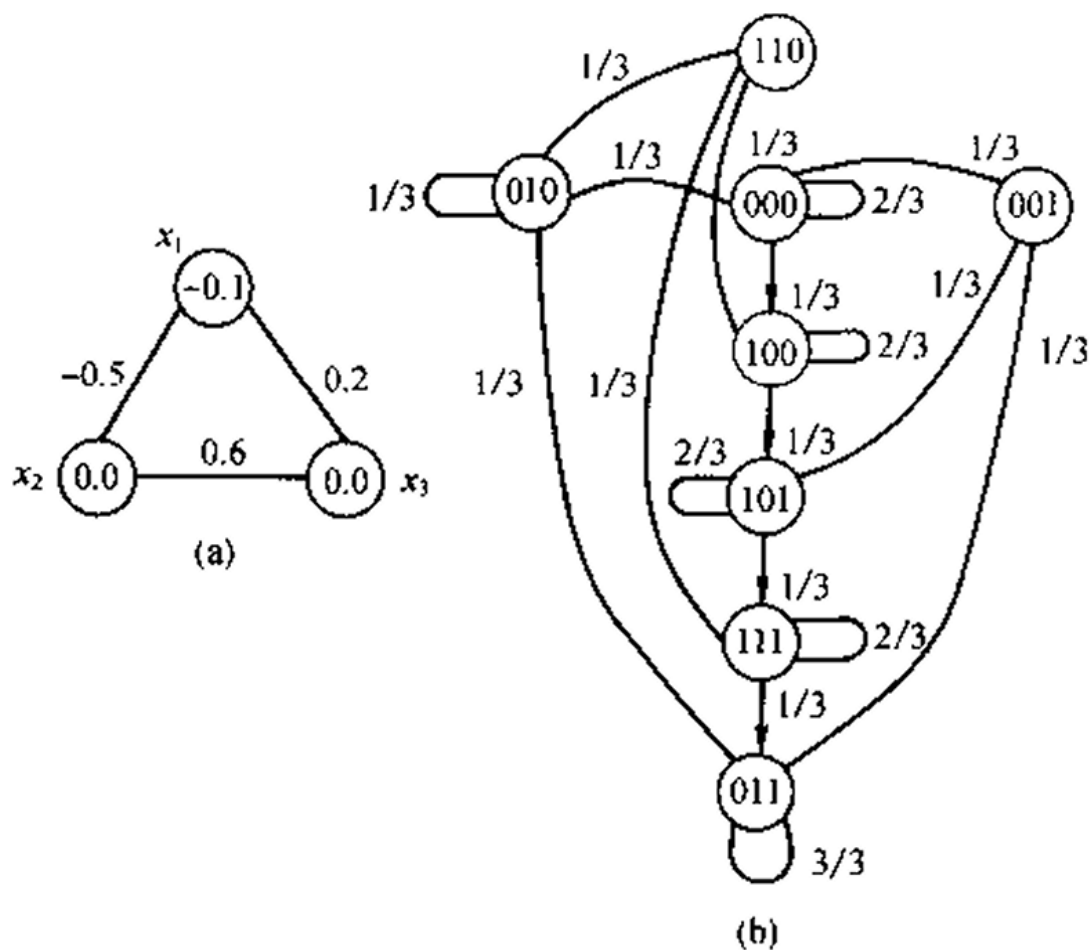
- 李雅普诺夫函数
- 在迭代过程中，能量函数不断下降
- 能量函数有下界
- 可以导出必定收敛到某个吸引子的结论

$$E(t) = -\frac{1}{2} \mathbf{X}^T(t) \mathbf{W} \mathbf{X}(t) + \mathbf{X}^T(t) \mathbf{T}$$

性质 1 若 \mathbf{X} 是网络的一个吸引子，且阈值 $T = 0$ ，在 $\text{sgn}(0)$ 处， $x_j(t+1) = x_j(t)$ ，则 $-\mathbf{X}$ 也一定是该网络的吸引子。

性质 2 若 \mathbf{X}^a 是网络的一个吸引子，则与 \mathbf{X}^a 的海明距离 $dH(\mathbf{X}^a, \mathbf{X}^b) = 1$ 的 \mathbf{X}^b 一定不是吸引子。

性质 3 若有一组向量 \mathbf{X}^p ($p = 1, 2, \dots, P$) 均是网络的吸引子，且在 $\text{sgn}(0)$ 处， $x_j(t+1) = x_j(t)$ ，则由该组向量线性组合而成的向量 $\sum_{p=1}^P a_p \mathbf{X}^p$ 也是该网络的吸引子。



- 韩立群书第126页
- 目标： W 矩阵满足特定要求，保证给定的样本是网络的吸引子，并要有一定的吸引域
- 联立方程法
- 外积和法
- 伪吸引子：非给定样本也成为网络的吸引子，他们不是网络设计所要求的解。一般对应于能量的某个局部极小点

定理 5.3 若 DHNN 网络的规模为 n ，且权矩阵主对角线元素为 0，则该网络的信息容量上界为 n 。

定理 5.4 若 P 个记忆模式 \mathbf{X}^p ， $p = 1, 2, \dots, P$ ， $x \in \{-1, 1\}^n$ 两两正交， $n > P$ ，且权值矩阵 \mathbf{W} 按式 (5.17) 得到，则所有 P 个记忆模式都是 DHNN 网 $(\mathbf{W}, \mathbf{0})$ 的吸引子。

定理 5.5 若 P 个记忆模式 \mathbf{X}^p ， $p = 1, 2, \dots, P$ ， $x \in \{-1, 1\}^n$ 两两正交， $n \geq P$ ，且权值矩阵 \mathbf{W} 按式 (5.16) 得到，则所有 P 个记忆模式都是 DHNN 网 $(\mathbf{W}, \mathbf{0})$ 的吸引子。

事实上，当网络规模 n 一定时，要记忆的模式数越多，联想时出错的可能性越大；反之，要求的出错概率越低，网络的信息存储容量上限越小。研究表明存储模式数 P 超过 $0.15n$ 时，联想时就有可能出错。错误结果对应的是能量的某个局部极小点，或称为伪吸引子。



图 9-4 固定噪声产生法数字识别结果

图 9-5 随机噪声产生法数字识别结果


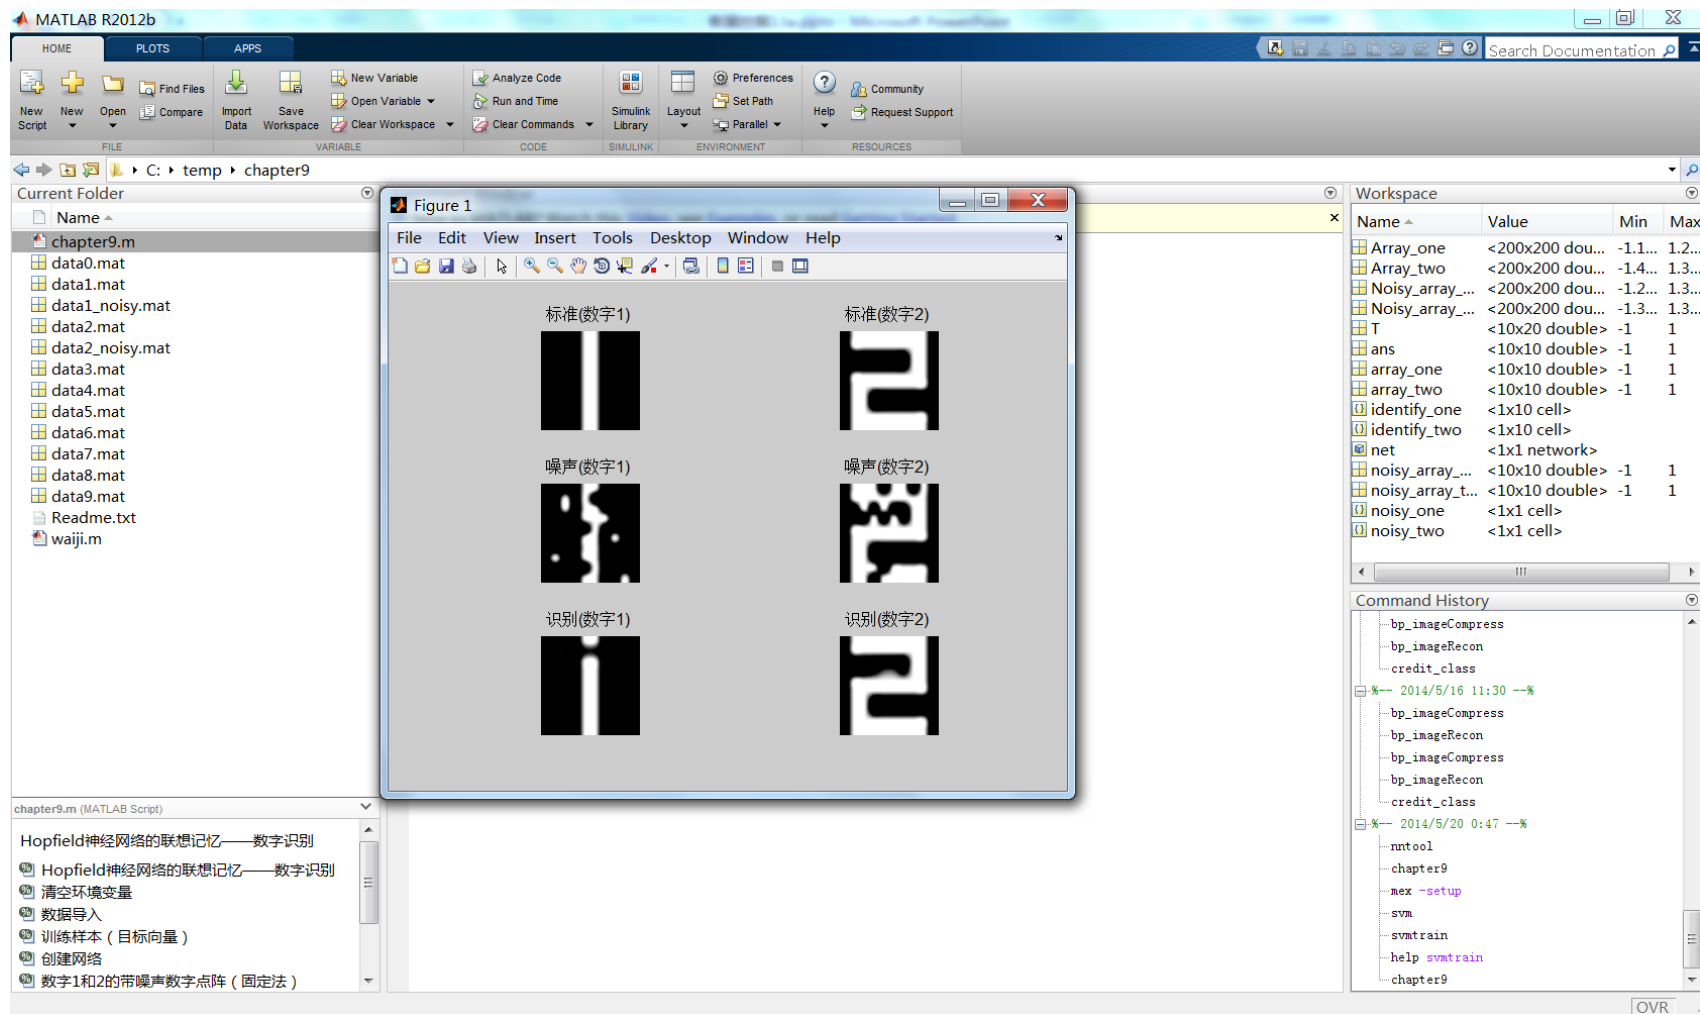


图 9-6 噪声强度为 0.2 时的识别结果

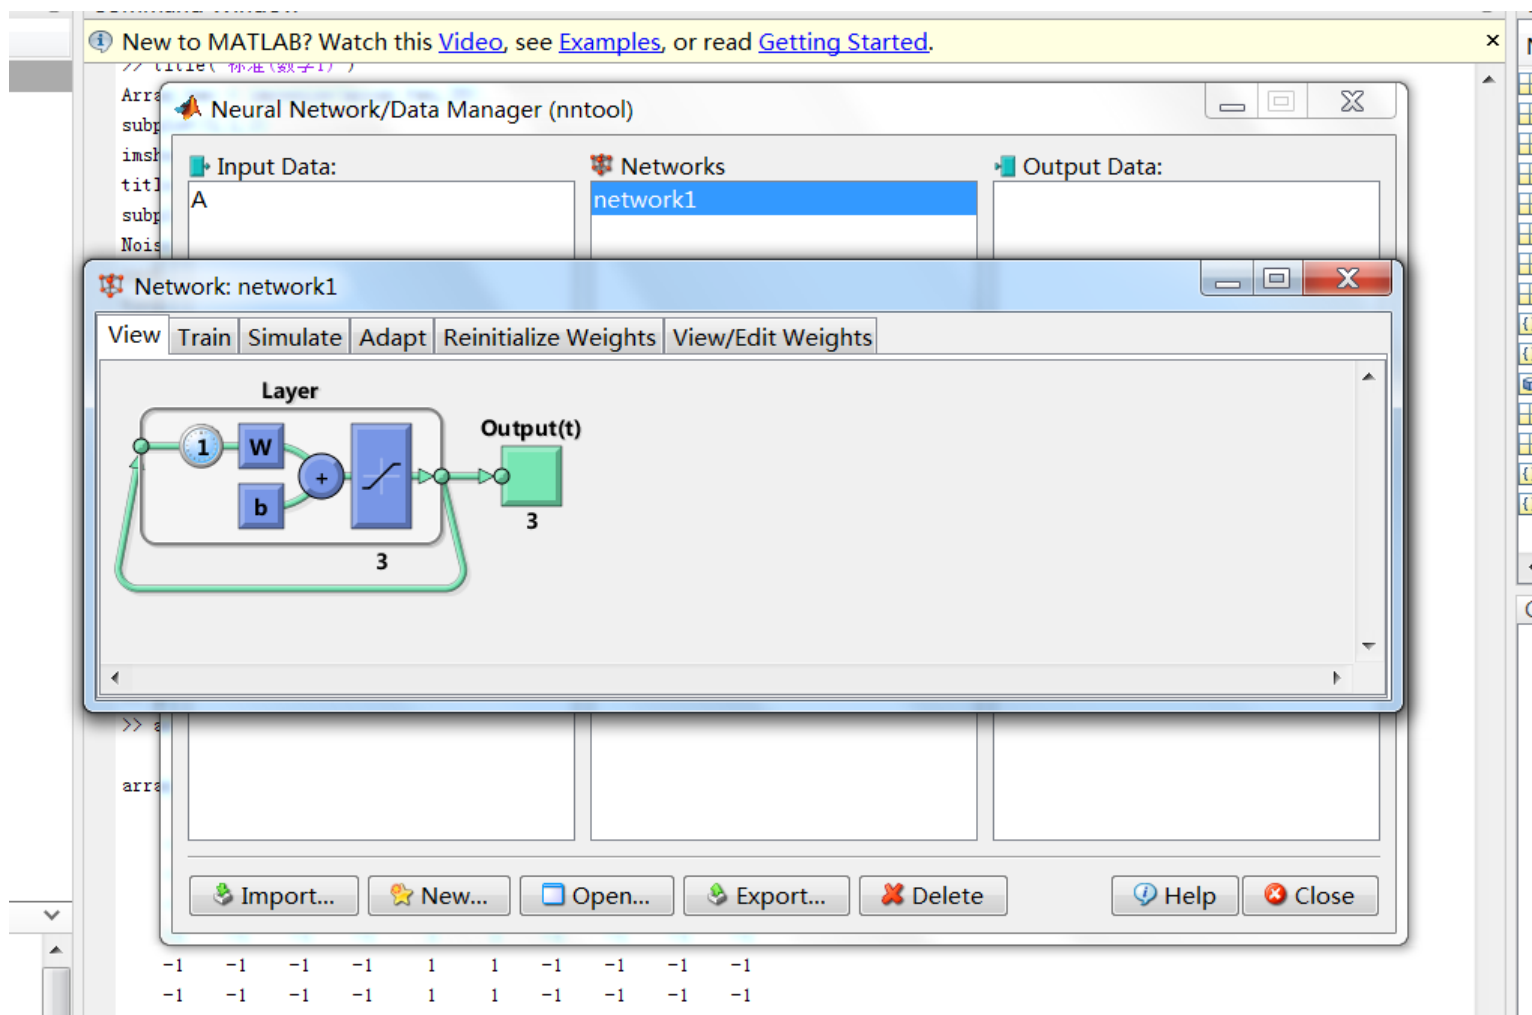
图 9-7 噪声强度为 0.3 时的识别结果

- 把图像信息数字化为1和-1二值矩阵
- 标准图样生成的矩阵作为Hopfield网络的目标向量
- 生成Hopfield网络
- 使用带噪音的矩阵测试
- 输出已经降噪，再和标准目标矩阵（向量）比对，找出最接近者

样例运行结果



创建Hopfield神经网络



- 《Matlab神经网络43个案例分析》第九章

■ CHNN

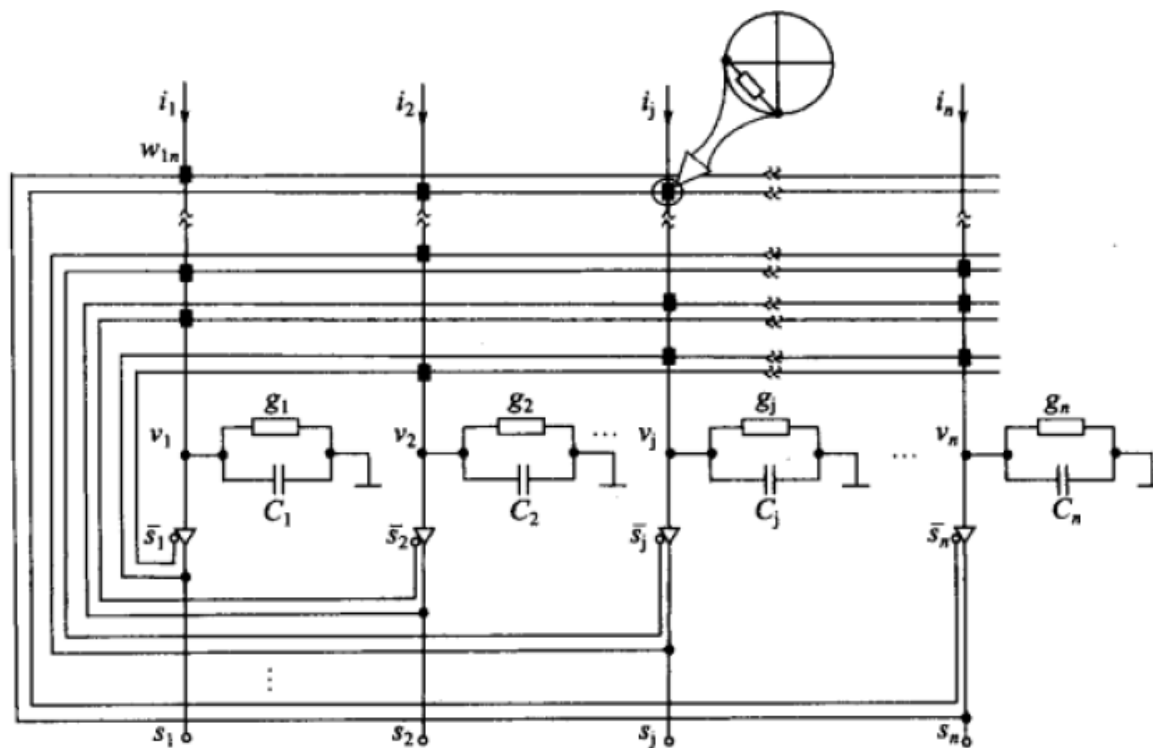


图 6.4 CHNN 的拓扑结构

定义 CHNN 的能量函数为：

$$E = -\frac{1}{2} \sum_{j=1}^n \sum_{i=1}^n w_{ij} v_i v_j - \sum_{j=1}^n v_j I_j + \sum_{j=1}^n \frac{1}{R_j} \int_0^{v_j} f^{-1}(\nu) d\nu \quad (6.21)$$

写成向量式为：

$$E = -\frac{1}{2} \mathbf{V}^T \mathbf{W} \mathbf{V} - \mathbf{I}^T \mathbf{V} + \sum_{j=1}^n \frac{1}{R_j} \int_0^{v_j} f^{-1}(\nu) d\nu \quad (6.22)$$

式中， f^{-1} 为神经元转移函数的反函数。对于式(6.21)所定义的能量函数，存在以下定理。

定理 6.6 若神经元的转移函数 f 存在反函数 f^{-1} ，且 f^{-1} 是单调连续递增的，同时网络权值对称，即 $w_{ij} = w_{ji}$ ，则由任意初态开始，CHNN 网络的能量函数总是单调递减的，即 $\frac{dE}{dt} \leq 0$ ，当且仅当 $\frac{dv_j}{dt} = 0$ 时，有 $\frac{dE}{dt} = 0$ ，因而网络最终能够达到稳态。

■ 韩立群书第131页






图 6.5 8 城市 TSP 问题中的有效路线换位阵



(a) 最优解



(b) 较佳解

- Dataguru（炼数成金）是专业数据分析网站，提供教育，媒体，内容，社区，出版，数据分析业务等服务。我们的课程采用新兴的互联网教育形式，独创地发展了逆向收费式网络培训课程模式。既继承传统教育重学习氛围，重竞争压力的特点，同时又发挥互联网的威力打破时空限制，把天南地北志同道合的朋友组织在一起交流学习，使到原先孤立的学习个体组合成有组织的探索力量。并且把原先动辄成千上万的学习成本，直线下降至百元范围，造福大众。我们的目标是：低成本传播高价值知识，构架中国第一的网上知识流转阵地。
- 关于逆向收费式网络的详情，请看我们的培训网站 <http://edu.dataguru.cn>



Thanks

FAQ时间